

LAPORAN UJIAN TENGAH SEMESTER
BUSINESS INTELLIGENCE
PERANCANGAN DATA WAREHOUSE CUACA HARIAN KEBUMEN

Dosen Pengampu: Dr. Akhmad Irsyad, S.T., M.Kom.



Disusun oleh:

Nanda Pesona Putri	2409116101
Nur Aliyya	2409116094
Rizky Yunia Surono	2409116089
Jihan Alya Naflah	2409116082

Program Studi Sistem Informasi
Fakultas Teknik
Universitas Mulawarman
2026

DAFTAR ISI

DAFTAR ISI	1
BAB I PENDAHULUAN	2
1.1 Latar Belakang	2
1.2 Tujuan Penelitian	2
BAB II PEMBAHASAN	3
2.1 Data Understanding	3
2.2 Perancangan Data Warehouse	5
2.2.1 Fact Table	5
2.2.2 Dimension Table	5
2.3 ETL (Extract, Transform, Load)	6
2.3.1 Extract	6
2.3.2 Transform	7
2.3.3 Load	17
2.4 Analisis Data	18
2.4.1 Analisis Kategori Produk Terlaris	19
2.4.2 Analisis Berdasarkan Lokasi	20
2.4.3 Analisis Tren Penjualan	21
BAB III PENUTUP	23
3.1 Kesimpulan	23
3.2 Saran	23

BAB I

PENDAHULUAN

1.1 Latar Belakang

Cuaca dan iklim merupakan faktor lingkungan yang memiliki pengaruh mendasar terhadap berbagai aspek kehidupan manusia, mulai dari sektor pertanian, pengelolaan sumber daya air, hingga mitigasi bencana hidrometeorologi. Di Indonesia, variabilitas cuaca bersifat kompleks dan dipengaruhi oleh posisi geografis negara yang berada di kawasan tropis, dinamika monsun Asia-Australia, serta fenomena iklim global seperti El Niño Southern Oscillation (ENSO) dan Indian Ocean Dipole (IOD).

Kabupaten Kebumen merupakan salah satu kabupaten di pesisir selatan Provinsi Jawa Tengah yang berbatasan langsung dengan Samudra Hindia. Letak geografis ini menjadikan Kebumen sebagai wilayah yang sangat rentan terhadap dinamika cuaca ekstrem. Wilayah Kebumen termasuk dalam daerah rawan bencana hidrometeorologi seperti banjir, banjir bandang, tanah longsor, angin kencang, dan puting beliung, terutama pada periode peralihan musim dan musim penghujan. Di sisi lain, pada musim kemarau wilayah ini juga berpotensi mengalami kekeringan yang berdampak pada ketahanan pangan lokal.

Dalam rangka mendukung analisis pola cuaca jangka panjang, pemodelan prediktif, serta pengambilan keputusan berbasis data, ketersediaan rekaman data meteorologi historis yang komprehensif menjadi sangat penting. Dataset ini memuat catatan observasi cuaca harian selama lebih dari empat dekade, mencakup variabel-variabel meteorologi seperti curah hujan, suhu udara, kelembapan, arah dan kecepatan angin, serta durasi penyinaran matahari.

Dengan cakupan temporal yang panjang dari tahun 1978 hingga 2022, dataset ini memiliki nilai strategis yang tinggi untuk berbagai keperluan, antara lain: analisis tren dan variabilitas iklim jangka panjang, deteksi anomali cuaca ekstrem, pengembangan model prediksi cuaca berbasis kecerdasan buatan, serta perencanaan mitigasi bencana dan adaptasi perubahan iklim di wilayah Kebumen dan sekitarnya. Ketersediaan dataset ini di platform Kaggle juga membuka peluang kolaborasi riset yang lebih luas bagi para peneliti, praktisi data, dan pemangku kebijakan di bidang meteorologi dan klimatologi.

1.2 Tujuan Penelitian

Berdasarkan latar belakang, dapat diketahui beberapa tujuan dari penelitian ini. Yaitu:

- 1) Membangun *data warehouse* berdasarkan dataset Cuaca Harian Kebumen yang digunakan.
- 2) Melakukan proses pengolahan data yang dilakukan yaitu meliputi *data understanding*, perancangan *data warehouse*, serta proses ETL (*Extract, Transform, Load*) dengan menggunakan bahasa pemrograman Python.
- 3) Mengimplementasikan hasil pengolahan data ke dalam sistem manajemen basis data menggunakan SQLite sebagai media penyimpanan data warehouse.
- 4) Menganalisis data untuk memperoleh informasi yang bermanfaat dalam mendukung pengambilan keputusan.

BAB II

PEMBAHASAN

2.1 Data Understanding

Tahap Data Understanding merupakan fondasi kritis dalam keseluruhan pipeline ETL. Pemahaman yang mendalam terhadap dataset sebelum proses transformasi dilakukan merupakan praktik terbaik dalam data engineering, karena keputusan cleaning dan imputasi yang keliru pada tahap awal akan merambat ke seluruh lapisan data warehouse dan menghasilkan analisis yang tidak valid.

2.1.1 Deskripsi Dataset

Dataset yang digunakan dalam proyek ini adalah Cuaca Harian Kebumen (1978–2022), yang diperoleh dari platform Kaggle (cuaca-harian-kebumen-1978-2022) dan bersumber dari rekaman observasi BMKG (Badan Meteorologi, Klimatologi, dan Geofisika) Stasiun Klimatologi Kebumen, Jawa Tengah. Dataset ini mencakup observasi harian selama lebih dari empat dekade dengan 20 variabel meteorologi.

Dataset dimuat menggunakan kode berikut:

```
df_raw = pd.read_csv(CSV_PATH, encoding='latin1', on_bad_lines='skip')

print('=' * 55)
print(' INFORMASI DASAR DATASET')
print('=' * 55)
print(f' Jumlah baris   : {df_raw.shape[0]:,} record')
print(f' Jumlah kolom    : {df_raw.shape[1]} variabel')

df_raw['datetime'] = pd.to_datetime(df_raw['datetime'], errors='coerce')
tgl_min = df_raw['datetime'].min().strftime('%d %B %Y')
tgl_max = df_raw['datetime'].max().strftime('%d %B %Y')
print(f' Periode data   : {tgl_min} -> {tgl_max}')
print(f' Sumber        : BMKG via Kaggle (jerismeteo)')
print(f' Lokasi        : Kebumen, Jawa Tengah, Indonesia')
print(f' Koordinat     : 7.67 deg S, 109.65 deg E | Elevasi +-15 mdpl')
print('=' * 55)
```

2.1.2 Kamus Data (Data Dictionary)

Dataset terdiri dari 20 variabel yang dapat dikelompokkan menjadi empat kategori fungsional: variabel temporal, variabel suhu, variabel presipitasi, dan variabel atmosfer. Pemahaman terhadap domain fisika atmosfer masing-masing variabel sangat penting untuk menentukan strategi imputasi yang tepat pada tahap Transform.

No	Nama Kolom	Tipe Data	Satuan	Keterangan
1	datetime	datetime	—	Tanggal observasi harian
2	tempmax	float	°C	Suhu udara maksimum harian
3	tempmin	float	°C	Suhu udara minimum harian
4	temp	float	°C	Suhu udara rata-rata harian
5	feelslikemax	float	°C	Suhu yang dirasakan (maks)
6	feelslikemin	float	°C	Suhu yang dirasakan (min)
7	feelslike	float	°C	Suhu yang dirasakan (rata-rata)
8	dew	float	°C	Titik embun (dew point)
9	humidity	float	%	Kelembapan udara relatif
10	precip	float	mm	Jumlah curah hujan harian
11	precipprob	float	%	Probabilitas terjadinya hujan
12	precipcover	float	%	Persentase waktu hujan dalam sehari
13	windspeed	float	km/h	Kecepatan angin rata-rata
14	winddir	float	°	Arah angin (0-360 derajat)
15	sealevelpressure	float	hPa	Tekanan udara permukaan laut
16	cloudcover	float	%	Persentase tutupan awan
17	visibility	float	km	Jarak pandang horizontal
18	sunrise	object	HH:MM	Waktu matahari terbit
19	sunset	object	HH:MM	Waktu matahari terbenam
20	conditions	object	—	Deskripsi kondisi cuaca (kategorik)

2.1.3 Statistik Deskriptif

Statistik deskriptif dihitung untuk variabel numerik utama guna memahami distribusi, rentang, dan karakteristik dasar dataset sebelum dilakukan transformasi.

```

numeric_cols = ['tempmax','tempmin','temp','humidity',
                'precip','windspeed','sealevelpressure',
                'cloudcover','visibility','dew']
numeric_cols = [c for c in numeric_cols if c in df_raw.columns]

desc = df_raw[numeric_cols].describe().T
desc.columns = ['N','Mean','Std','Min','Q1','Median','Q3','Max']
desc = desc.round(2)

```

```
print('-- Statistik Deskriptif Variabel Utama --')
print(desc.to_string())
```

Interpretasi statistik deskriptif mengungkap karakteristik iklim Kebumen sebagai berikut:

- 1) Suhu udara (temp): rata-rata 26–28 °C, konsisten dengan iklim tropis Jawa Tengah. Rentang suhu harian (maks–min) sekitar 8–10 °C mencerminkan amplitudo termal moderat khas pesisir selatan Jawa yang dimoderasi kelembapan Samudra Hindia.
- 2) Kelembapan (humidity): rata-rata tinggi (>70%), wajar untuk wilayah pesisir tropis. Nilai kelembapan yang konsisten tinggi ini menjadi faktor penting dalam strategi imputasi — imputasi dengan nilai nol akan sangat menyesatkan.
- 3) Curah hujan (precip): distribusi sangat right-skewed, dengan sebagian besar hari memiliki curah hujan nol atau sangat rendah namun sesekali terjadi hujan ekstrem. Ini mengimplikasikan bahwa mean bukan ukuran pusat yang representatif untuk kolom ini.
- 4) Kecepatan angin (windspeed): relatif rendah dan variansinya kecil, mencerminkan kondisi angin moderat khas dataran rendah pantai. Ini memvalidasi penggunaan median sebagai strategi imputasi karena distribusinya mendekati simetris.
- 5) Tekanan udara (sealevelpressure): stabil di sekitar 1010–1015 hPa, normal untuk wilayah tropis. Nilai ekstrem yang jarang muncul mengindikasikan kejadian cuaca ekstrem yang perlu dipertahankan, bukan dihapus.

2.1.4 Analisis Distribusi Data

Analisis distribusi dilakukan dengan histogram untuk memahami bentuk sebaran setiap variabel. Pemilihan metode imputasi pada tahap Transform sangat bergantung pada hasil analisis distribusi ini.

```
viz_cols = {
    'temp'      : 'Suhu Rata-rata (C)',
    'humidity'  : 'Kelembapan (%)',
    'precip'    : 'Curah Hujan (mm)',
    'windspeed' : 'Kecepatan Angin (km/h)',
    'sealevelpressure': 'Tekanan Udara (hPa)',
    'cloudcover' : 'Tutupan Awan (%)'
}

fig, axes = plt.subplots(2, 3, figsize=(15, 8))
colors =
['steelblue', 'mediumseagreen', 'tomato', 'mediumpurple', 'goldenrod', 'cornflowerblue']

for i, (col, label) in enumerate(viz_cols.items()):
    data = df_raw[col].dropna()
    axes[i].hist(data, bins=50, color=colors[i], alpha=0.80)
    axes[i].axvline(data.mean(), color='red', linestyle='--', label=f'Mean')
    axes[i].axvline(data.median(), color='black', linestyle=':', label=f'Median')
    axes[i].set_title(label, fontweight='bold')
    axes[i].legend()
```

2.1.5 Identifikasi Outlier

Deteksi outlier menggunakan metode IQR (Interquartile Range). Nilai dianggap outlier apabila berada di luar rentang $[Q1 - 1.5 \times IQR, Q3 + 1.5 \times IQR]$.

```
box_cols = ['tempmax','tempmin','temp','humidity',
            'precip','windspeed','cloudcover','visibility']

for i, (col, lbl) in enumerate(zip(box_cols, labels)):
    data = df_raw[col].dropna()
    Q1, Q3 = data.quantile(0.25), data.quantile(0.75)
    IQR = Q3 - Q1
    n_out = ((data < Q1 - 1.5*IQR) | (data > Q3 + 1.5*IQR)).sum()
    axes[i].set_xlabel(f'Outlier: {n_out:}, ({n_out/len(data)*100:.1f}%)')
```

Temuan dari analisis outlier:

- 6) **Curah hujan (precip):** memiliki outlier paling banyak. Hal ini wajar karena distribusinya memang right-skewed — hujan ekstrem merupakan kejadian nyata yang perlu dipertahankan dalam rekaman historis.
- 7) **Suhu (temp, tempmax, tempmin):** outlier minimal, menandakan suhu di Kebumen relatif stabil sepanjang periode pengamatan selama 44 tahun. Ini konsisten dengan karakteristik iklim tropis yang minim variabilitas suhu tahunan.
- 8) **Kelembapan dan tutupan awan:** sebaran cukup normal dengan sedikit outlier. Nilai ekstrem yang ada kemungkinan besar mencerminkan kejadian iklim aktual seperti kemarau panjang atau La Nina.

2.2 Perancangan Data Warehouse

Perancangan data warehouse merupakan tahap arsitekturisasi yang menentukan bagaimana data akan disimpan, diorganisasi, dan diakses untuk kebutuhan analisis multidimensional. Keputusan desain pada tahap ini berdampak langsung pada performa query, kemudahan pemeliharaan, dan skalabilitas sistem jangka panjang.

2.2.1 Struktur Star Schema dan Relasi Antar Tabel

Star Schema yang dirancang terdiri dari satu fact table sentral dan tiga tabel dimensi. Setiap tabel dimensi terhubung ke fact table melalui Foreign Key surrogate yang dibuat secara eksplisit, bukan natural key, untuk menjaga konsistensi dan performa JOIN.

dim_waktu	dim_lokasi	dim_kondisi_cuaca	fact_cuaca_harian
PK: date_iddatetime, harinama_hari, tanggalbulan, nama_bulankuartal, tahunmusim,	PK: lokasi_idnama_loka sinama_stasiun kabupatenprovinsi, pulaulatitude,	PK: kondisi_idcondition skategori_hujanting kat_ekstrem	PK: fact_idFK: date_idFK: lokasi_idFK: kondisi_idtempmax, tempmintemp, feelslikedew,

sunrisesunsetdurasi_ siang_menit	longitudeelevasi_md plumber_data		humidityprecip, precipprobprecipcov erwindspeed, winddirsealevelpres surecloudcover, visibility
-------------------------------------	-------------------------------------	--	--

2.2.3 Pertimbangan Desain Setiap Tabel Dimensi

a. dim_waktu

Tabel dimensi waktu dirancang dengan prinsip richness — menyertakan sebanyak mungkin atribut temporal yang mungkin dibutuhkan untuk analisis OLAP tanpa perlu JOIN ke tabel lain. Kolom-kolom yang di-derive seperti nama_hari, nama_bulan, kuartal, musim, dan durasi_siang_menit merupakan contoh konversi dari data mentah menjadi informasi analitik yang langsung dapat digunakan.

b. dim_lokasi

Tabel dimensi lokasi hanya memiliki satu baris karena dataset ini merepresentasikan satu stasiun tunggal (BMKG Kebumen). Meskipun kardinalitasnya minimal, tabel ini dipertahankan sebagai tabel dimensi untuk memenuhi prinsip desain star schema dan memudahkan perluasan sistem di masa depan apabila data dari stasiun lain perlu diintegrasikan — cukup menambahkan baris baru di dim_lokasi tanpa mengubah skema fact table.

c. dim_kondisi_cuaca

Dimensi ini diperluas dari sekadar menyimpan nilai unik kolom conditions dengan menambahkan dua kolom klasifikasi: kategori_hujan dan tingkat_ekstrem. Pengayaan (enrichment) ini dilakukan melalui aturan bisnis berbasis kata kunci yang mencerminkan pengetahuan domain meteorologi.

```
def klasifikasi_kondisi(cond):
    c = str(cond).lower()
    if 'rain' in c or 'storm' in c or 'thunder' in c or 'shower' in c:
        return 'Hujan', 'Tinggi'
    elif 'overcast' in c or 'cloud' in c or 'fog' in c or 'mist' in c:
        return 'Berawan', 'Sedang'
    elif 'clear' in c or 'sun' in c:
        return 'Cerah', 'Rendah'
    else:
        return 'Campuran', 'Sedang'

dim_kondisi[['kategori_hujan', 'tingkat_ekstrem']] = \
    dim_kondisi['conditions'].apply(lambda x: pd.Series(klasifikasi_kondisi(x)))
```

2.3 Proses ETL (Extract, Transform, Load)

Pipeline ETL yang dibangun mengikuti prinsip single-responsibility — setiap tahap memiliki tanggung jawab yang jelas dan tidak tumpang tindih. Pendekatan ini memudahkan debugging, pengujian, dan pemeliharaan sistem dalam jangka panjang.

2.3.1 Extract — Pemuatan Data Mentah

Tahap Extract bertujuan memuat data dari sumber (CSV) ke dalam memori tanpa melakukan modifikasi apapun. Prinsip ini penting untuk menjaga auditabilitas pipeline — apabila terjadi masalah, selalu mungkin untuk membandingkan data sebelum dan sesudah transformasi.

```
df_raw = pd.read_csv(CSV_PATH, encoding='latin1', on_bad_lines='skip')
print(f'Raw shape : {df_raw.shape}')
print(f'Kolom      : {list(df_raw.columns)}')

# Audit missing values pada data mentah
missing = df_raw.isnull().sum()
missing_pct = (missing / len(df_raw) * 100).round(2)
pd.DataFrame({'Missing': missing, 'Persen (%)': missing_pct}) \
    .query('Missing > 0') \
    .sort_values('Persen (%)', ascending=False)
```

Tahap Extract menghasilkan snapshot data mentah yang menjadi baseline untuk mengukur dampak setiap langkah transformasi. Jumlah missing values, distribusi tipe data, dan rentang nilai pada tahap ini dicatat sebagai referensi.

2.3.2 Transform — Pembersihan dan Rekonstruksi Data

Tahap Transform merupakan tahap paling kompleks dalam pipeline ini dan dibagi menjadi lima sub-tahap yang terurut. Urutan eksekusi sub-tahap ini dirancang secara hati-hati karena beberapa operasi saling bergantung — misalnya, konversi tipe datetime harus dilakukan sebelum operasi berbasis waktu seperti forward fill.

a. T1 — Seleksi Kolom (Drop Threshold)

Kolom dengan proporsi missing values melebihi 40% dieliminasi dari dataset. Threshold 40% dipilih berdasarkan pertimbangan bahwa imputasi pada kolom dengan lebih dari separuh nilai yang hilang berpotensi menghasilkan informasi yang lebih bersifat artifisial daripada representatif.

```
threshold = 0.4
df = df_raw.loc[:, df_raw.isnull().mean() < threshold].copy()
print(f'Kolom dibuang (>40% null) : {df_raw.shape[1] - df.shape[1]}')
print(f'Kolom tersisa           : {df.shape[1]}')

# Normalisasi nama kolom (hapus karakter kutip dan spasi)
df.columns = df.columns.str.replace('"', '').str.strip()
```

b. T2 — Konversi Tipe Data dan Deduplication

Konversi kolom datetime ke tipe yang tepat dilakukan sebelum operasi lain. Parameter `errors='coerce'` memastikan nilai yang tidak dapat diparse dikonversi ke `NaT` daripada menyebabkan kegagalan pipeline. Duplikat dihapus karena satu tanggal hanya boleh memiliki satu observasi harian.

```
df['datetime'] = pd.to_datetime(df['datetime'], errors='coerce')

before_dedup = len(df)
df = df.drop_duplicates().reset_index(drop=True)
print(f'Duplikat dihapus: {before_dedup - len(df)} baris')
```

c. T3 — Strategi Imputasi Berbasis Domain

Setiap kolom mendapatkan strategi imputasi yang berbeda, dipilih berdasarkan pengetahuan domain meteorologi, bukan hanya pertimbangan statistik semata. Tabel berikut merangkum keputusan dan rasionalnya:

Kelompok Kolom	Strategi	Metode	Justifikasi Domain
precip, precipprob, precipcover	Imputasi 0	<code>fillna(0)</code>	Null berarti tidak ada pencatatan hujan, yang dalam meteorologi diinterpretasikan sebagai tidak terjadi hujan
winddir, windspeed	Imputasi Median	<code>fillna(median())</code>	Median lebih robust terhadap outlier kecepatan angin ekstrem yang sesekali muncul
Semua numerik lain	Imputasi Median	<code>fillna(median())</code>	Distribusi variabel suhu dan tekanan mendekati simetris, median dan mean relatif setara
conditions (kategorik)	Imputasi Modus	<code>fillna(mode()[0])</code>	Tidak ada operasi aritmatika pada teks; modus adalah nilai yang paling konservatif
datetime	Forward Fill	<code>ffill()</code>	Urutan kronologis harus dipertahankan; tanggal sebelumnya adalah referensi terbaik

```
# Imputasi curah hujan -> 0 (tidak ada hujan)
rain_cols = [c for c in ['precip', 'precipprob', 'precipcover'] if c in df.columns]
for col in rain_cols:
    df[col] = df[col].fillna(0)

# Imputasi angin -> median
wind_cols = [c for c in ['winddir', 'windspeed'] if c in df.columns]
for col in wind_cols:
    df[col] = df[col].fillna(df[col].median())

# Imputasi numerik lain -> median
```

```

numeric_cols = df.select_dtypes(include=['float64', 'int64']).columns
skip = set(rain_cols + wind_cols)
for col in numeric_cols:
    if col not in skip:
        df[col] = df[col].fillna(df[col].median())

# Imputasi kategorik -> modus
cat_cols = df.select_dtypes(include='object').columns.tolist()
for col in cat_cols:
    df[col] = df[col].fillna(df[col].mode()[0])

# Imputasi datetime -> forward fill
df['datetime'] = df['datetime'].ffill()

# Validasi akhir
sisas = df.isnull().sum().sum()
print(f'Sisa missing values : {sisas}')

```

d. T4 — Feature Engineering: Derive Kolom Waktu

Kolom-kolom temporal baru di-derive dari kolom datetime untuk memperkaya dimensi waktu. Setiap kolom yang di-derive memiliki nilai analitik langsung yang mempermudah query OLAP tanpa perlu komputasi ulang di sisi klien.

```

df['hari'] = df['datetime'].dt.dayofweek + 1 # 1=Senin, 7=Minggu
df['nama_hari'] = df['datetime'].dt.day_name()
df['tanggal'] = df['datetime'].dt.day
df['bulan'] = df['datetime'].dt.month
df['nama_bulan'] = df['datetime'].dt.month_name()
df['kuartal'] = df['datetime'].dt.quarter
df['tahun'] = df['datetime'].dt.year
df['musim'] = df['bulan'].map(
    lambda m: 'Hujan' if m in [10, 11, 12] else 'Kemarau'
)

# Derive durasi siang dari sunrise dan sunset
sr = pd.to_datetime(df['sunrise'], errors='coerce')
ss = pd.to_datetime(df['sunset'], errors='coerce')
df['durasi_siang_menit'] = (ss - sr).dt.total_seconds() / 60

```

e. T5 — Pembangunan Tabel Dimensi dan Fact Table

Setelah cleaning dan feature engineering, data siap distrukturisasi ke dalam skema star. Setiap tabel dimensi dibangun dengan prinsip uniqueness — tidak ada duplikat pada natural key-nya.

```

# dim_waktu: satu baris per tanggal unik
dim_waktu =
df[waktu_cols].drop_duplicates(subset='datetime').reset_index(drop=True)
dim_waktu.insert(0, 'date_id', range(1, len(dim_waktu) + 1))

```

```
# dim_lokasi: hard-coded karena satu stasiun
dim_lokasi = pd.DataFrame([
    'lokasi_id': 1, 'nama_lokasi': 'Kebumen, Indonesia',
    'latitude': -7.6728, 'longitude': 109.6453, 'elevasi_mdpl': 15,
    ...})

# fact_cuaca_harian: merge FK dari semua dimensi
fact = df.copy()
fact = fact.merge(dim_waktu[['date_id', 'datetime']], on='datetime', how='left')
fact['lokasi_id'] = 1
fact = fact.merge(dim_kondisi[['kondisi_id', 'conditions']], on='conditions',
    how='left')
fact_cuaca = fact[['date_id', 'lokasi_id', 'kondisi_id'] + measure_cols].copy()
fact_cuaca.insert(0, 'fact_id', range(1, len(fact_cuaca) + 1))
```

2.3.3 Load — Penyimpanan ke Data Warehouse SQLite

Tahap Load menyimpan seluruh tabel ke database SQLite dengan menambahkan indeks untuk mengoptimalkan performa query. SQLite dipilih sebagai target database karena sifatnya yang serverless dan portable — cocok untuk tahap pengembangan dan analisis eksploratori.

```
engine = create_engine(f'sqlite:/// {DB_PATH}')

# Validasi: pastikan semua DataFrame tidak kosong sebelum load
assert len(dim_waktu) > 0, 'ABORT: dim_waktu kosong!'
assert len(fact_cuaca) > 0, 'ABORT: fact_cuaca_harian kosong!'

# Load semua tabel
dim_waktu.to_sql('dim_waktu', engine, if_exists='replace', index=False)
dim_lokasi.to_sql('dim_lokasi', engine, if_exists='replace', index=False)
dim_kondisi.to_sql('dim_kondisi_cuaca', engine, if_exists='replace', index=False)
fact_cuaca.to_sql('fact_cuaca_harian', engine, if_exists='replace', index=False)

# Buat indeks untuk optimasi query
with engine.connect() as conn:
    conn.execute(text('CREATE UNIQUE INDEX IF NOT EXISTS idx_pk_waktu ON
dim_waktu(date_id)'))
    conn.execute(text('CREATE UNIQUE INDEX IF NOT EXISTS idx_pk_fact ON
fact_cuaca_harian(fact_id)'))
    conn.execute(text('CREATE INDEX IF NOT EXISTS idx_fk_date_id ON
fact_cuaca_harian(date_id)'))
    conn.execute(text('CREATE INDEX IF NOT EXISTS idx_fk_kondisi_id ON
fact_cuaca_harian(kondisi_id)'))
    conn.commit()
```

2.3.4 Validate — Verifikasi Integritas Referensial

Tahap validasi memverifikasi dua aspek kritis: (1) tidak ada nilai NULL pada kolom Foreign Key di fact table, dan (2) seluruh nilai FK memiliki padanan di tabel dimensi yang sesuai (no orphan records). Kegagalan pada salah satu cek ini mengindikasikan masalah serius pada logika JOIN di tahap Transform.

```

# Cek 1: NULL check pada semua FK
fk_check = {
    'date_id' : fact_cuaca['date_id'].isnull().sum(),
    'lokasi_id' : fact_cuaca['lokasi_id'].isnull().sum(),
    'kondisi_id' : fact_cuaca['kondisi_id'].isnull().sum(),
}

# Cek 2: Referential integrity (orphan records)
orphan_date = ~fact_cuaca['date_id'].isin(dim_waktu['date_id'])
orphan_lokasi = ~fact_cuaca['lokasi_id'].isin(dim_lokasi['lokasi_id'])
orphan_kondisi = ~fact_cuaca['kondisi_id'].isin(dim_kondisi['kondisi_id'])

checks = {
    'date_id -> dim_waktu' : orphan_date.sum(),
    'lokasi_id -> dim_lokasi' : orphan_lokasi.sum(),
    'kondisi_id -> dim_kondisi' : orphan_kondisi.sum(),
}
for rel, n in checks.items():
    status = 'OK' if n == 0 else f'{n} ORPHAN RECORDS'
    print(f'{rel}: {status}')

```

2.4 Visualisasi dan Analisis Data

Tahap visualisasi dilakukan terhadap data yang telah tersimpan di data warehouse dengan melakukan query langsung ke SQLite. Pendekatan ini memvalidasi bahwa data warehouse berfungsi dengan benar sebagai sumber analisis, sekaligus menghasilkan insight yang bermakna dari data cuaca historis Kebumen.

2.4.1 Pola Suhu Bulanan


Query berikut mengambil rata-rata suhu maksimum, minimum, dan rata-rata yang diagregasi per bulan dari data 44 tahun, kemudian divisualisasikan sebagai grafik garis dengan area rentang suhu.

```

df_bulan = query("""
SELECT
    w.bulan, w.nama_bulan,
    ROUND(AVG(f.tempmax), 2) AS avg_tempmax,
    ROUND(AVG(f.temp), 2) AS avg_temp,
    ROUND(AVG(f.tempmin), 2) AS avg_tempmin
FROM fact_cuaca_harian f
JOIN dim_waktu w ON f.date_id = w.date_id
GROUP BY w.bulan, w.nama_bulan
ORDER BY w.bulan
""")

ax.fill_between(x, df_bulan['avg_tempmin'], df_bulan['avg_tempmax'],
    alpha=0.2, color='steelblue', label='Rentang Suhu')
ax.plot(x, df_bulan['avg_temp'], marker='o', color='steelblue',
    linewidth=2.5, label='Suhu Rata-rata')

```




Interpretasi: Grafik menunjukkan pola suhu bulanan yang relatif stabil, khas wilayah tropis. Suhu rata-rata tertinggi terjadi pada Oktober–November yang bertepatan dengan awal musim hujan, di mana radiasi matahari masih tinggi namun tutupan awan mulai meningkat. Suhu terendah umumnya pada Juli–Agustus saat musim kemarau puncak, ketika massa udara kering dari Australia mendominasi. Rentang antara suhu maksimum dan minimum harian sekitar 5–8 °C mencerminkan amplitudo termal moderat pesisir selatan Jawa.

2.4.2 Tren Suhu Tahunan (1978–2022)

Visualisasi tren suhu tahunan menggunakan Plotly untuk menghasilkan grafik interaktif yang memudahkan eksplorasi data historis. Query mengagregasi data per tahun dari fact table.

```
df_tahun = query("""
SELECT w.tahun,
       ROUND(AVG(f.tempmax), 2) AS avg_tempmax,
       ROUND(AVG(f.temp), 2) AS avg_temp,
       ROUND(AVG(f.tempmin), 2) AS avg_tempmin
FROM fact_cuaca_harian f
JOIN dim_waktu w ON f.date_id = w.date_id
GROUP BY w.tahun ORDER BY w.tahun
""")

fig2.add_trace(go.Scatter(
    x=df_tahun['tahun'], y=df_tahun['avg_temp'],
    mode='lines+markers', name='Suhu Rata-rata',
    line=dict(color='steelblue', width=3)
))
```




Interpretasi: Tren tahunan memperlihatkan kecenderungan kenaikan suhu rata-rata secara gradual dari 1978 hingga 2022, konsisten dengan fenomena pemanasan global yang teramati di Asia Tenggara. Lonjakan suhu yang lebih tajam terlihat sejak awal 2000-an, bertepatan dengan meningkatnya frekuensi El Nino yang lebih intens. Variabilitas suhu tahunan yang besar pada beberapa tahun mengindikasikan pengaruh kuat ENSO (El Nino-Southern Oscillation) terhadap iklim lokal Kebumen.

2.4.3 Distribusi Kondisi Cuaca

Visualisasi distribusi kondisi cuaca mengkombinasikan diagram batang dan pie chart untuk memberikan perspektif frekuensi absolut dan proporsi relatif secara bersamaan.

```
df_kondisi = query("""
SELECT k.conditions,
       COUNT(*) AS jumlah_hari,
       ROUND(COUNT(*) * 100.0 /
             (SELECT COUNT(*) FROM fact_cuaca_harian), 1) AS persen
FROM fact_cuaca_harian f
JOIN dim_kondisi_cuaca k ON f.kondisi_id = k.kondisi_id
GROUP BY k.conditions ORDER BY jumlah_hari DESC
""")
```

```
fig3 = make_subplots(rows=1, cols=2,
                     specs=[[{'type':'bar'}, {'type':'pie'}]])
fig3.add_trace(go.Bar(x=df_kondisi['conditions'],
                      y=df_kondisi['jumlah_hari'], ...), row=1, col=1)
fig3.add_trace(go.Pie(labels=df_kondisi['conditions'],
                      values=df_kondisi['jumlah_hari'], hole=0.35), row=1, col=2)
```



Interpretasi: Distribusi kondisi cuaca memperlihatkan dominasi hari berawan dan hujan sepanjang periode pengamatan, mencerminkan karakteristik iklim tropis basah Kebumen. Kondisi cerah (clear) hanya terjadi pada sebagian kecil hari, terutama terkonsentrasi di Juli–September saat musim kemarau. Tingginya proporsi hari berawan dan hujan berdampak langsung pada sektor pertanian di Kebumen dan memvalidasi pentingnya klasifikasi tingkat_ekstrem di `dim_kondisi_cuaca` untuk analisis risiko pertanian.


2.4.4 Analisis Curah Hujan per Musim

Analisis ini mengeksplorasi kolom musim yang di-derive pada tahap Transform untuk membandingkan total curah hujan dan probabilitas hujan antara musim hujan dan kemarau di setiap tahun.

```
df_hujan = query("""
SELECT w.tahun, w.musim,
       ROUND(SUM(f.precip), 2) AS total_precip,
       ROUND(AVG(f.precipprob), 1) AS avg_prob_hujan
FROM fact_cuaca_harian f
JOIN dim_waktu w ON f.date_id = w.date_id
GROUP BY w.tahun, w.musim ORDER BY w.tahun, w.musim
""")
```

```
sns.barplot(data=df_hujan, x='tahun', y='total_precip',
            hue='musim', palette={'Hujan':'steelblue', 'Kemarau':'sandybrown'},
            ax=axes[0])
```

Analisis Curah Hujan — Kebumen



Interpretasi: Perbedaan curah hujan antara musim hujan dan kemarau sangat signifikan — musim hujan (Oktober–Maret) menyumbang lebih dari 75% total curah hujan tahunan. Pola ini konsisten dengan dominasi Monsun Asia yang membawa uap air dari Laut China Selatan menuju Jawa bagian selatan. Variabilitas antar tahun yang besar mengindikasikan pengaruh ENSO: tahun-tahun La Nina menunjukkan curah hujan musim hujan yang sangat tinggi, sementara tahun El Nino memiliki musim kemarau yang lebih panjang dari normal.

2.4.5 Heatmap Korelasi Antar Variabel


Analisis korelasi menggunakan heatmap segitiga bawah untuk menghindari redundansi visual. Pemilihan kolom difokuskan pada variabel yang memiliki makna fisik yang dapat diinterpretasikan.

```
df_num = query("""
    SELECT tempmax, tempmin, temp, feelslike, dew, humidity,
           precip, precipprob, windspeed, cloudcover,
           sealevelpressure, visibility
    FROM fact_cuaca_harian
    """)

corr = df_num.corr()

# Masking untuk segitiga bawah (menghindari redundansi)
mask = pd.DataFrame(False, index=corr.index, columns=corr.columns)
mask.values[np.triu_indices_from(mask, k=1)] = True

sns.heatmap(corr, mask=mask, annot=True, fmt='.2f',
            cmap='RdYlGn', center=0, vmin=-1, vmax=1,
            linewidths=0.5, square=True)
```



Interpretasi: Heatmap korelasi mengungkap beberapa hubungan fisik yang dapat divalidasi secara ilmiah:

1. Suhu dan titik embun (dew): berkorelasi positif kuat — semakin tinggi suhu, semakin tinggi kapasitas udara menampung uap air, sehingga titik embun juga lebih tinggi.
2. Suhu dan kelembapan: berkorelasi negatif — pada hari panas dan cerah, kelembapan relatif turun meskipun kandungan uap air absolut tinggi. Fenomena ini memiliki implikasi penting bagi indeks kenyamanan termal.
3. Curah hujan dan tutupan awan: berkorelasi positif — hari hujan selalu disertai tutupan awan tinggi, sesuai prinsip dasar fisika atmosfer.
4. Visibilitas dan tutupan awan: berkorelasi negatif — semakin tebal awan, jarak pandang semakin terbatas. Korelasi ini relevan untuk keselamatan penerbangan dan transportasi laut.
5. Tekanan udara dan curah hujan: berkorelasi negatif lemah — tekanan rendah sering dikaitkan dengan sistem cuaca aktif (low pressure system) yang memicu hujan.

BAB III

PENUTUP

3.1 Kesimpulan

Berdasarkan hasil penelitian, proses pembangunan data warehouse menggunakan metode *ETL (Extract, Transform, Load)* dengan bantuan Python dan SQLite berhasil dilakukan dengan baik. Data yang semula tidak terstruktur berhasil diolah menjadi bentuk *star schema* yang terdiri dari tabel fakta dan tabel dimensi.

Dengan demikian, data warehouse yang dibangun mampu mendukung proses analisis data secara lebih terstruktur dan efektif.

3.2 Saran

Adapun saran yang dapat diberikan dari hasil penelitian sejauh ini adalah sebagai berikut:

1. Pengembangan sistem dapat dilakukan dengan menambahkan visualisasi data menggunakan tools seperti Tableau atau Power BI.
2. Penelitian selanjutnya dapat mengembangkan model analisis yang lebih kompleks untuk mendapatkan insight yang lebih mendalam.